



Захист програмного продукту

За темою “Використання великої мовної моделі для адаптивного збору інформації з веб сторінок”



Завдання, мета та вимоги розробки



Витягування даних

Вкажіть URL веб-сторінки та опис потрібних даних — система автоматично структурує вміст за допомогою великої мовної моделі.

URL веб-сторінки

Інструкція для вилучення (необов'язково)

Схема вихідних даних у форматі JSON (необов'язково)

Запустити

Класичні збирачі інформації (скрейпери) прив'язані до структури сайтів. Вони ламаються навіть при дрібних оновленнях дизайну, потребують налаштування під кожен сайт.

Мета - створити адаптивний, тобто незалежний від структури будь-якого сайту, інструмент, що збирає та структурує дані засобами LLM.



Вимоги:

- Працювати з науковими джерелами без змін у коді
- Виокремлювати структуровані поля: методологія, висновки, ключові слова
- Підтримувати експорт і двомовний інтерфейс (EN / UA)

Архітектура застосунку

Фаза 1 — Виявлення та фільтрація:

- Паралельний запит до 5 API: OpenAlex, Crossref, Semantic Scholar, arXiv, CORE
- Дедублікація за DOI, потім за нормалізованим заголовком
- LLM оцінює кожну статтю від 0 до 10 за релевантністю



Фаза 2 — Вилучення змісту:

- Crawl4AI завантажує сторінку як браузер → перетворює на чистий текст
- Пейвол → автоматичне перемикання на Jina Reader
- DeepSeek-V4-Flash витягує методологію, висновки, ключові слова
- Опціональний переклад українською; експорт у JSON / CSV / BibTeX

Як працює застосунок



Нове дослідження

Введіть наукову тему — система побудує каталог релевантних статей.

Тема дослідження

наприклад: Machine learning in web scraping

Кількість статей у каталозі: 10

Не раніше року (необов'язково): 2015

Мова виводу: Англійська (оригінал) ▼

Джерела пошуку

☒ OpenAlex ☒ Semantic Scholar ☒ arXiv ☒ CORE ☐ Crossref

☒ Тільки open-access

Запустити

Сервер: Python + FastAPI

База даних: SQLite

Інтерфейс: SvelteKit (EN + UA), прогрес збирання інформації у реальному часі

Три режими:

- Дослідницький — каталог наукових статей за темою
- Універсальний збирач — будь-який URL + опис потрібних даних
- Бенчмарк — LLM vs trafilatura + BeautifulSoup, порівняння

Отримані результати

В результаті роботи розроблено:

- Систему автоматизованого збору наукових статей із 5 відкритих API
- Модуль вилучення структурованих даних засобами LLM без прив'язки до структури сторінки
- Універсальний інструмент збору даних з довільних веб-сторінок
- Веб-інтерфейс із підтримкою EN/UA та експортом у JSON / CSV / BibTeX
- Порівняльний аналіз LLM vs класичні методи (trafilatura + BeautifulSoup)
- Система працює як повноцінний веб-застосунок за посиланням

<https://news-scraper.app>

